

JPEG Sıkıştırması, Bulanıklık ve Gürültünün Deepfake Tespit Performansına Etkisi

[AD SOYAD]
[ÜNİVERSİTE / BÖLÜM]
[e-posta@kurum.edu.tr]

Özet

Deepfake manipölasyonlarının yaygınlaşması, otomatik tespit sistemlerinin güvenilirliğini kritik bir araştırma konusu haline getirmiştir. Literatürdeki modeller çoğunlukla yüksek kaliteli veya standart sıkıştırılmış veri kümeleri üzerinde değerlendirilmekte; gerçek dünyada karşılaşılan JPEG sıkıştırması, bulanıklık ve gürültü gibi kalite kayıplarının etkisi ise sınırlı ölçüde incelenmektedir. Bu çalışmada, FaceForensics++ veri kümesinin Deepfakes alt kümesi (c23 sıkıştırma) üzerinde önceden eğitilmiş Xception modelinin, kontrollü olarak uygulanan üç tür görüntü bozulması altındaki dayanıklılığı sistematik biçimde analiz edilmiştir. Deneylerde 60 test karesine JPEG kalite faktörleri (90-10), Gaussian bulanıklık çekirdekleri (3-11) ve Gaussian gürültü standart sapmaları ($\sigma=5-40$) uygulanmış; performans AUC, doğruluk, F1, kesinlik ve duyarlılık metrikleriyle ölçülmüştür. Temiz test koşulunda model AUC=1,00 elde ederken, en ağır gürültü koşulunda ($\sigma=40$) AUC 0,56'ya düşmüştür. Bulanıklık (çekirdek=11) ve ağır JPEG sıkıştırması (q=10) sırasıyla AUC=0,95 ve AUC=0,98 değerlerine yol açmıştır. Bulgular, görüntü kalitesindeki düşüşün tespit performansını azalttığı hipotezini desteklemekte ve en kritik bozulma türünün gürültü olduğunu ortaya koymaktadır.

Anahtar Kelimeler: deepfake tespiti, görüntü kalitesi, JPEG sıkıştırması, Gaussian bulanıklık, Gaussian gürültü, Xception, FaceForensics++

Abstract

The proliferation of deepfake manipulations has made the reliability of automatic detection systems a critical research topic. Models in the literature are mostly evaluated on high-quality or standard compressed datasets, while the impact of real-world quality degradations such as JPEG compression, blur, and noise remains insufficiently studied. In this study, the robustness of a pre-trained Xception model on the Deepfakes subset of FaceForensics++ (c23 compression) is systematically analyzed under three types of controlled image degradation. JPEG quality factors (90-10), Gaussian blur kernels (3-11), and Gaussian noise standard deviations ($\sigma=5-40$) were applied to 60 test frames; performance was measured using AUC, accuracy, F1, precision, and recall. While the model achieved AUC=1.00 on clean test data, severe noise ($\sigma=40$) reduced AUC to 0.56. Blur (kernel=11) and heavy JPEG compression (q=10) yielded AUC=0.95 and AUC=0.98, respectively. The findings support the hypothesis that detection performance degrades with image quality loss and identify noise as the most critical degradation type.

Keywords: deepfake detection, image quality, JPEG compression, Gaussian blur, Gaussian noise, Xception, FaceForensics++

1. Giriş

Yapay zekâ destekli yüz değiştirme (deepfake) teknolojileri, sosyal medya ve haber kaynaklarında güvenilirliği zedeleyen sahte içeriklerin üretimini kolaylaştırmaktadır [1]. Bu

gelişmeye paralel olarak, manipüle edilmiş yüz videolarını otomatik olarak ayırt etmeye yönelik derin öğrenme tabanlı tespit yöntemleri geliştirilmiştir [1], [2]. FaceForensics++ (FF++) veri kümesi, farklı manipülasyon türleri ve sıkıştırma seviyeleri sunarak bu alandaki standart karşılaştırma platformlarından biri haline gelmiştir [1].

Ancak akademik değerlendirmelerin büyük bölümü kontrollü laboratuvar koşullarında gerçekleştirilmektedir. Gerçek dünyada paylaşılan görüntü ve videolar ek sıkıştırma, yeniden örnekleme, hareket bulanıklığı ve sensör gürültüsüne maruz kalmaktadır. Rössler ve ark. [1], FF++ üzerinde c23'ten c40 sıkıştırmasına geçildiğinde Xception modelinin doğruluğunun %95,73'ten yaklaşık %81'e düştüğünü göstermiştir. Bu durum kalite kaybının tespit performansını doğrudan etkilediğini göstermekte; farklı bozulma türlerinin göreceli etkilerini aynı deneysel protokol altında karşılaştırma gereksinimini ortaya çıkarmaktadır.

Bu çalışmanın amacı, önceden eğitilmiş Xception tabanlı bir deepfake tespit modelinin JPEG sıkıştırması, Gaussian bulanıklık ve Gaussian gürültü altındaki performansını nicel olarak incelemektir. Araştırma sorusu, kontrollü görüntü bozulmalarının modelin AUC değerini nasıl etkilediği biçiminde formüle edilmiştir. Çalışmanın hipotezi, görüntü kalitesi düştükçe tespit performansının azalacağı yönündedir.

Çalışmanın katkıları üç başlık altında özetlenebilir: (i) aynı test kareleri üzerinde üç farklı bozulma türünün adil biçimde karşılaştırılması, (ii) bozulma şiddeti ile AUC arasındaki ilişkinin grafiksel ve sayısal olarak raporlanması ve (iii) laboratuvar koşullarındaki yüksek başarının gerçek dünya benzeri kalite kayıpları altında nasıl değiştiğinin ortaya konulması.

2. İlgili Çalışmalar

Deepfake tespiti. Afchar ve ark. [2], hafif MesoNet mimarisini önermiştir. FF++ c23 üzerindeki %83,10 benchmark skoru ise Rössler ve ark. [1] tarafından raporlanmıştır. Aynı çalışmada Xception için yüz kırpması kullanıldığında c23'te %95,73, ham veride %99,26 doğruluk bildirilmiştir [1]. Chollet [3] tarafından önerilen Xception, derinlikli ayrılabilir evrişim yapısı nedeniyle yüz manipülasyonu tespitinde yaygın biçimde kullanılmaktadır.

Sıkıştırma ve dayanıklılık. FF++ kapsamında c0, c23 ve c40 sıkıştırma seviyeleri tanımlanmıştır [1]. Yasser ve ark. [4], kendi kurulumlarında EfficientNet-B4 ve XceptionNet için sırasıyla %95,59 ve %89,91 AUC bildirmiştir. Baek ve ark. [5] ise LFWS için sekiz benchmark genelinde %78,60 ortalama AUC raporlamıştır. Farklı veri bölmeleri ve deney protokolleri nedeniyle bu değerler doğrudan karşılaştırılabilir değildir.

Kalite bozulması. Literatürde JPEG artefaktları ve video yeniden sıkıştırması üzerine çalışmalar mevcut olmakla birlikte [1], Gaussian bulanıklık ile eklemeli Gaussian gürültünün aynı deneysel protokol altında karşılaştırıldığı çalışmalar daha sınırlıdır. Bu çalışma, farklı kalite bozulmalarının aynı model ve aynı test kareleri üzerindeki göreceli etkisini incelemektedir.

3. Materyal ve Yöntem

3.1 Veri kümesi ve bölünme

Çalışmada FaceForensics++ veri kümesinin Deepfakes manipülasyon alt kümesi ve c23 sıkıştırma seviyesi kullanılmıştır [1]. Toplam 20 gerçek ve 20 sahte video seçilmiş; her videodan 10 kare çıkarılarak 400 görüntü elde edilmiştir. Veri bölünmesi video bazlı yapılmış; 280 kare eğitim, 60 kare doğrulama ve 60 kare test alt kümelerine ayrılmıştır. Bununla birlikte bu projede model eğitimi yapılmamış, yalnızca önceden eğitilmiş ağırlıklarla test gerçekleştirilmiştir. Test

kümesi 30 gerçek ve 30 sahte kareden oluşmaktadır. Şekil 1'de veri kümesinden örnek gerçek ve sahte kareler gösterilmektedir.

Veri seti örnekleri



Şekil 1. FaceForensics++ c23 veri kümesinden örnek gerçek (sol) ve Deepfakes sahte (sağ) kareler.

3.2 Tespit modeli

Değerlendirmede Rössler ve ark. [1] tarafından FF++ c23 üzerinde eğitilmiş Xception modelinin full_c23.p ağırlık dosyası kullanılmıştır. Bu çalışmada model yeniden eğitilmemiş; dondurulmuş ağırlıklarla yalnızca çıkarım (inference) yapılmıştır. Böylece ölçülen performans farklarının test karelerine uygulanan bozulmalardan kaynaklanması amaçlanmıştır.

3.3 Bozulma prosedürü

Kontrollü bozulmalar yalnızca test kümesindeki 60 kareye uygulanmıştır. Her bozulma türü için kullanılan parametreler Tablo 1'de özetlenmektedir.

Tablo 1. Uygulanan bozulma türleri ve parametre seviyeleri

Bozulma türü	Parametre	Seviyeler	Uygulama yöntemi
JPEG sıkıştırma	Kalite (q)	90, 70, 50, 30, 10	OpenCV imencode
Gaussian bulanıklık	Çekirdek (k)	3, 5, 7, 11	cv2.GaussianBlur
Gaussian gürültü	Standart sapma (σ)	5, 10, 20, 40	Eklemeli normal gürültü

Toplam 13 bozulma koşulu ve bir adet bozulmasız (baseline) referans koşulu değerlendirilmiştir. Şekil 2-4'te her bozulma türünün şiddet artışına bağlı görsel etkisi aynı referans kare üzerinde gösterilmektedir.

JPEG sıkıştırma ilerlemesi (aynı kare)



Şekil 2. JPEG sıkıştırma ilerlemesi (q=90, 70, 50, 30, 10).

Gaussian blur ilerlemesi (aynı kare)



Şekil 3. Gaussian bulanıklık ilerlemesi ($k=3, 5, 7, 11$).

Gaussian gürültü ilerlemesi (aynı kare)



Şekil 4. Gaussian gürültü ilerlemesi ($\sigma=5, 10, 20, 40$).

3.4 Değerlendirme metrikleri

Sınıflandırma performansı doğruluk (Accuracy), alıcı işletim karakteristiği eğrisi altındaki alan (AUC), F1 skoru, kesinlik (Precision) ve duyarlılık (Recall) ile ölçülmüştür. Birincil karşılaştırma metriği AUC olarak seçilmiştir. AUC, tek bir karar eşiğine bağlı kalmadan gerçek ve sahte sınıfları ayırma başarısını ölçerken; doğruluk, F1, kesinlik ve duyarlılık seçilen karar eşiğindeki sınıflandırma davranışını göstermektedir. Baseline ve en ağır gürültü koşulu için karışıklık matrisleri ayrıca incelenmiştir.


4. Deneysel Sonuçlar

4.1 Baseline performans

Bozulmasız test koşulunda model tüm metriklerde 1,00 değerine ulaşmıştır (Tablo 2). Şekil 5'teki karışıklık matrisinde 30 gerçek ve 30 sahte karenin tamamının doğru sınıflandırıldığı görülmektedir.

Tablo 2. Bozulmasız (baseline) test sonuçları

Accuracy	AUC	F1	Precision	Recall
1,00	1,00	1,00	1,00	1,00




Şekil 5. Baseline koşulunda karışıklık matrisi.

4.2 JPEG sıkıştırma sonuçları

Tablo 3'te JPEG koşullarındaki performans değerleri verilmektedir. $q \geq 30$ seviyelerinde AUC değişmemiş ve 1,00 olarak korunmuştur. Yalnızca en ağır sıkıştırma düzeyi olan $q=10$ 'da AUC 0,98'e, doğruluk ise 0,97'ye düşmüştür. Şekil 6, JPEG kalite faktörü ile AUC arasındaki ilişkiyi göstermektedir.

Tablo 3. JPEG bozulma koşulları sonuçları

Koşul	Accuracy	AUC	F1	Precision	Recall
jpeg_q90	1,00	1,00	1,00	1,00	1,00
jpeg_q70	1,00	1,00	1,00	1,00	1,00
jpeg_q50	1,00	1,00	1,00	1,00	1,00
jpeg_q30	1,00	1,00	1,00	1,00	1,00
jpeg_q10	0,97	0,98	0,97	1,00	0,93




Şekil 6. JPEG kalite faktörüne göre AUC değişimi.

4.3 Bulanıklık sonuçları

Gaussian bulanıklık çekirdek boyutu arttıkça eşik tabanlı metriklerde ve en ağır koşulda AUC değerinde düşüş gözlenmiştir (Tablo 4). $k=3$ koşulunda tüm değerler 1,00 iken, $k=11$ koşulunda AUC 0,95'e ve doğruluk 0,85'e gerilemiştir. $k=5$ ve $k=7$ koşullarında AUC 1,00 kalmasına rağmen doğruluğun azalması, sıralama başarısının korunduğunu ancak sabit karar eşiğinin bazı örneklerde hatalı sınıflandırma ürettiğini göstermektedir. Şekil 7 AUC değişimini sunmaktadır.

Tablo 4. Gaussian bulanıklık koşulları sonuçları

Koşul	Accuracy	AUC	F1	Precision	Recall
blur_k3	1,00	1,00	1,00	1,00	1,00
blur_k5	0,97	1,00	0,97	0,94	1,00
blur_k7	0,93	1,00	0,94	0,88	1,00
blur_k11	0,85	0,95	0,87	0,78	0,97




Şekil 7. Bulanıklık çekirdek boyutuna göre AUC değişimi.

4.4 Gürültü sonuçları


Gürültü bozulması, incelenen koşullar içinde en belirgin performans düşüşünü üretmiştir (Tablo 5). $\sigma \leq 10$ seviyelerinde performans değişmemiş; $\sigma=20$ 'de AUC 0,97'ye ve doğruluk 0,85'e düşmüştür. $\sigma=40$ koşulunda AUC 0,56'ya gerileyerek rastgele ayırma yakın bir düzeye ulaşmıştır. Bu koşulda sahte karelerin yalnızca %7'si doğru tespit edilmiş (Recall=0,07) ve 30 sahte karenin 28'i gerçek olarak sınıflandırılmıştır. Şekil 8-10 gürültü etkisini ve en kötü koşulun karışıklık matrisini göstermektedir.

Tablo 5. Gaussian gürültü koşulları sonuçları


Koşul	Accuracy	AUC	F1	Precision	Recall
noise_s5	1,00	1,00	1,00	1,00	1,00
noise_s10	1,00	1,00	1,00	1,00	1,00
noise_s20	0,85	0,97	0,84	0,92	0,77
noise_s40	0,53	0,56	0,13	1,00	0,07



Şekil 8. Gürültü standart sapmasına göre AUC değişimi.



Şekil 9. Her bozulma türündeki en kötü AUC değerlerinin karşılaştırılması.



Şekil 10. $\sigma=40$ gürültü koşulunda karışıklık matrisi (AUC=0,56).

4.5 Özet karşılaştırma

Her bozulma türünün en ağır koşulunda elde edilen AUC değerleri Tablo 6'da özetlenmektedir. Baseline'a göre AUC kaybı JPEG için 0,02, bulanıklık için 0,05 ve gürültü için 0,44'tür.

Tablo 6. Bozulma türlerine göre en kötü AUC değerleri

Bozulma türü	En iyi koşul (AUC)	En kötü koşul	En kötü AUC	Δ AUC
JPEG	q90-q30 (1,00)	q10	0,98	-0,02
Bulanıklık	k3 (1,00)	k11	0,95	-0,05
Gürültü	σ 5-10 (1,00)	σ 40	0,56	-0,44

5. Tartışma

Deneyisel bulgular, görüntü kalitesindeki düşüşün deepfake tespit performansını azalttığı hipotezini desteklemektedir. Bununla birlikte etki düzeyi bozulma türüne göre önemli ölçüde değişmiştir. Ağır gürültü, model performansını neredeyse rastgele ayırım seviyesine indirirken JPEG sıkıştırması ve bulanıklık daha sınırlı kayıplara yol açmıştır.

JPEG dayanıklılığı. Model $q \geq 30$ JPEG sıkıştırmasına karşı tam AUC dayanıklılığı sergilemiştir. Bu durum, kullanılan modelin c23 sıkıştırılmış FF++ verisi üzerinde eğitilmiş olmasıyla tutarlıdır [1]. Yalnızca aşırı sıkıştırma ($q=10$) küçük bir AUC düşüşü oluşturmuştur. Dolayısıyla model, eğitim dağılımına yakın sıkıştırma artefaktlarına karşı görece kararlı görünmektedir.

Bulanıklık etkisi. Çekirdek boyutu arttıkça yüz ayrıntıları ve yüksek frekanslı kenar bilgileri kaybolduğundan modelin kullandığı manipülasyon izleri zayıflamıştır. Buna rağmen en ağır bulanıklık koşulundaki AUC kaybı 0,05 ile sınırlı kalmıştır. Buna karşılık doğruluğun 0,85'e düşmesi, sınıflandırma eşliğinin bulanıklık altında yeniden kalibre edilmesinin yararlı olabileceğine işaret etmektedir.

Gürültü etkisi. $\sigma=40$ koşulundaki dramatik performans çöküşü (AUC=0,56), eklemeli gürültünün manipülasyon izlerini maskeleyebildiğini göstermektedir. Model bu koşulda sahte

karelerin büyük bölümünü gerçek olarak sınıflandırmıştır. Bu bulgu, düşük ışık, yüksek ISO, sensör paraziti veya iletim kaynaklı bozulma içeren gerçek dünya videolarında ciddi güvenilirlik riski doğurabileceğini göstermektedir.

Literatür karşılaştırması. Tablo 7’de güncel yöntemlerin yayımlanmış sonuçları özetlenmektedir. MesoNet’in %83,10 değeri özgün mimari makalesinden değil, FF++ benchmark çalışmasından alınmıştır [1], [2]. Ayrıca [4] ve [5] farklı deney protokolleri kullandığından skorlar doğrudan üstünlük karşılaştırması amacı taşımaz. Bu çalışmadaki baseline AUC=1,00 değeri de küçük test alt kümesi ve tek manipülasyon türüyle sınırlıdır.

Tablo 7. Literatür ile sonuçların karşılaştırılması

Yöntem	Yıl	Veri kümesi	Metrik	Skor	Kaynak
MesoNet	2018	FF++ c23	Accuracy	%83,10	[1]
Xception (face crop)	2019	FF++ c23	Accuracy	%95,73	[1]
Xception (face crop)	2019	FF++ raw	Accuracy	%99,26	[1]
EfficientNet-B4	2023	FF++ c23*	AUC	%95,59	[4]
LFWS	2026	8 benchmark*	Ort. AUC	%78,60	[5]
Bu çalışma (baseline)	2026	FF++ alt küme, c23	AUC	1,00	-
Bu çalışma (noise $\sigma 40$)	2026	FF++ alt küme, c23+noise	AUC	0,56	-

Sınırlamalar. Çalışmanın temel sınırlamaları; 40 video ve 60 test karesinden oluşan küçük alt küme, yalnızca Deepfakes manipülasyon türünün incelenmesi, yüz kırpma (face crop) uygulanmaması, tek bir model ve checkpoint kullanılması ve deneylerin CPU ortamında yürütülmesidir. Ayrıca kareler aynı videolardan geldiği için kare düzeyindeki metrikler tamamen bağımsız örnekler olarak yorumlanmamalıdır. Gelecek çalışmalarda daha geniş veri kümeleri, çoklu manipülasyon türleri, video düzeyinde değerlendirme ve gürültüye dayanıklı veri artırımıyla eğitilmiş modeller incelenmelidir.

6. Sonuç

Bu bildiride, FaceForensics++ c23 verisi üzerinde önceden eğitilmiş Xception modelinin JPEG sıkıştırması, Gaussian bulanıklık ve Gaussian gürültü altındaki dayanıklılığı sistematik olarak incelenmiştir. Temiz test koşulunda mükemmel performans (AUC=1,00) elde edilirken, kalite kaybı arttıkça tespit başarısı azalmıştır. En kritik bozulma türü Gaussian gürültü ($\sigma=40$, AUC=0,56) olmuş; bunu güçlü bulanıklık ($k=11$, AUC=0,95) ve ağır JPEG sıkıştırması ($q=10$, AUC=0,98) izlemiştir. Sonuç olarak laboratuvar koşullarında mükemmel çalışan Xception modeli, gerçek dünya benzeri ağır gürültü altında AUC=0,56 seviyesine düşmektedir. Bu bulgu, deepfake tespit sistemlerinde gürültü dayanıklılığının ve bozulma farkındalıklı eğitimin öncelikli araştırma konuları olması gerektiğini göstermektedir.

Kaynakça

- [1] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies ve M. Nießner, “FaceForensics++: Learning to Detect Manipulated Facial Images,” Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), 2019.
- [2] D. Afchar, V. Nozick, J. Yamagishi ve I. Echizen, “MesoNet: A Compact Facial Video Forgery Detection Network,” Proc. IEEE Int. Workshop on Information Forensics and Security (WIFS), 2018.
- [3] F. Chollet, “Xception: Deep Learning with Depthwise Separable Convolutions,” Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2017.
- [4] B. Yasser et al., “Deepfake Detection Using EfficientNet and XceptionNet,” Proc. 11th Int. Conf. Intelligent Computing and Information Systems (ICICIS), ss. 598-603, 2023, doi: 10.1109/ICICIS58388.2023.10391114.
- [5] S. Baek, T. Anwaar, K. Singh ve R. Singh, “Lightweight Complementary-Cue Fusion for Robust Video Face Forgery Detection,” arXiv:2605.29092, 2026.